

Đại học Quốc gia Hà Nội
Trường Đại học Công nghệ



BÁO CÁO DỰ ÁN

Transformers và Diffusion cho bài toán Dịch máy

Môn học :

Học sâu

Giảng viên :

PGS.TS. Nguyễn Việt Hà
ThS. Nguyễn Thị Thùy Linh

Thành viên nhóm

Mã sinh viên

Vũ Minh Sơn

23020424

Lâm Đức Anh

23020326

Nguyễn Bá Quang

23020412

Hà Nội, 2025

Mục lục

Tóm tắt	1
1 Giới thiệu	2
1.1 Đặt vấn đề	2
1.1.1 Bối cảnh	2
1.1.2 Các vấn đề tồn tại	2
1.1.3 Nhu cầu cấp thiết	3
1.2 Mục tiêu dự án	3
1.3 Phạm vi dự án	4
1.3.1 Giới hạn	4
2 Nghiên cứu liên quan	5
2.1 Dịch máy Nơ-ron Tự hồi quy	5
2.2 Dịch máy Nơ-ron Không tự hồi quy	5
2.3 Mô hình Khuếch tán cho Sinh văn bản	6
3 Cơ sở lý thuyết	7
3.1 Bài toán Dịch máy Nơ-ron	7
3.1.1 Khung kiến trúc Encoder-Decoder	7
3.1.2 Huấn luyện và Tối ưu hóa	7
3.2 Kiến trúc Transformer	8
3.2.1 Cơ chế Scaled Dot-Product Attention	9
3.2.2 Cơ chế Multi-Head Attention	9
3.2.3 Mã hóa vị trí	9
3.2.4 Cơ chế giải mã Tự hồi quy	10

3.3	Mô hình Diffusion	10
3.3.1	Một số định nghĩa	10
3.3.2	Làm nhiều	11
3.3.3	Học giải nhiều	11
3.3.4	Giải nhiều có điều kiện	12
3.3.5	Suy luận	12
4	Phương pháp thiết kế	14
4.1	Mô hình xương sống	14
4.2	Tiền huấn luyện	14
4.3	Huấn luyện	15
4.4	Suy luận	15
5	Kết quả	16
5.1	Tổng hợp kết quả định lượng	16
5.2	Phân tích chi tiết và Thảo luận	17
5.2.1	Các mô hình tiền huấn luyện (Pre-trained Models)	17
5.2.2	Trả lời câu hỏi nghiên cứu	18
6	Tổng kết	20
6.1	Kết luận	20
6.2	Hướng mở rộng	20
	Tài liệu tham khảo	21
A	Thành viên	22

Tóm tắt

Sau một thập kỷ phát triển, dịch máy nơ-ron đã đạt được những bước tiến lớn và trở thành một công nghệ quan trọng trong xử lý ngôn ngữ tự nhiên. Trong bước tiến đó có dấu chân của Transformer, một kiến trúc tiên tiến dựa trên cơ chế Attention hiện đang là tiêu chuẩn cho hầu hết các bài toán ngôn ngữ. Tuy nhiên, Transformer tồn tại một số hạn chế cần được khắc phục, chẳng hạn như exposure bias hay quá trình sinh token tuần tự và cứng nhắc. Hai vấn đề này sẽ được nhắc đến trong báo cáo này.

Transformer hay tổng quát hơn là họ các mô hình autoregressive với cơ chế sinh tuần tự chậm chạp và cứng nhắc đang thách thức các nhà nghiên cứu tìm ra một phương pháp mới để giải quyết vấn đề trên: một giải pháp sinh nhanh hơn và đa dạng hơn. Trong quá trình tìm kiếm, người ta bắt đầu nhớ đến ý tưởng Diffusion, một mô hình đang thống trị tác vụ sinh ảnh trong lĩnh vực Thị giác máy tính, thử nghiệm nó cho việc sinh văn bản. Tuy chỉ mới xuất hiện và hiệu suất chưa sánh được Transformers, nhưng với đặc điểm là độ phức tạp thời gian suy luận là hằng số và các mẫu sinh đem lại độ đa dạng cao, nó đã cho thấy một tiềm năng to lớn của mình. Vì vậy, chúng tôi quyết định thực hiện tìm hiểu và cài đặt loại mô hình này cho tác vụ dịch máy và so sánh chúng với các mô hình truyền thống. Chúng tôi sử dụng bộ dữ liệu IWSLT15 làm bộ dữ liệu chính để đánh giá hiệu năng của mô hình đề xuất và so sánh với các mô hình khác.

Thực nghiệm cho thấy mô hình Diffusion đúng thực sự có khả năng sinh ra văn bản đa dạng với tốc độ suy luận hằng số. Song chúng vẫn chưa thể bằng các mô hình Transformers truyền thống về mặt định lượng. Mặc dù vậy, kết quả định tính với Diffusion cho kết quả khả quan và tích cực, nên ta có thể tin rằng đây là một hướng đi tiềm năng, có thể khai thác để nghiên cứu tiếp theo.

Chương 1

Giới thiệu

1.1 Đặt vấn đề

1.1.1 Bối cảnh

Dịch máy Nơ-ron đóng vai trò quan trọng trong việc giảm thiểu bất đồng ngôn ngữ, khiến việc giao tiếp giữa người với người trên các lãnh thổ khác nhau trở nên dễ dàng hơn, từ lý do đó việc nghiên cứu các kiến trúc mô hình hiệu quả trở nên cần thiết hơn bao giờ hết. Trong thập kỷ qua, sự chuyển dịch từ các mô hình thống kê sang các mạng nơ-ron hồi quy như RNN hay LSTM [10] và gần đây nhất là kiến trúc Transformer dựa trên cơ chế Attention [11], đã tạo ra những cột mốc mới về chất lượng dịch thuật. Hiện nay, Transformer là giải pháp tiêu biểu và được sử dụng phổ biến hầu hết các bảng xếp hạng nhờ khả năng xử lý phụ thuộc xa và khả năng song song hóa vượt trội so với LSTM trước đó. Các nghiên cứu thực nghiệm trên quy mô lớn đã chứng minh Transformer vượt qua RNN và CNN về chỉ số BLEU trên các cặp ngôn ngữ phổ biến [1]. Mặc dù đã đạt được những thành tựu như vậy, nhưng về mặt kiến trúc, Transformer vẫn đối diện với những vấn đề sau:

1.1.2 Các vấn đề tồn tại

Qua nghiên cứu lý thuyết và khảo sát thực nghiệm, dự án xác định hai vấn đề chính mà các hệ thống hiện tại đang gặp phải:

- **Vấn đề Exposure Bias:** Đây là một nhược điểm phổ biến của các mô hình sinh văn bản tự hồi quy như Transformer. Về bản chất, vấn đề này xuất phát từ sự khác biệt giữa quá trình huấn luyện sử dụng Teacher Forcing và quá trình suy diễn sử dụng đầu ra dự đoán trước đó [2]. Các giải pháp tiêu biểu như Scheduled Sampling đã cố gắng giảm thiểu khoảng cách này nhưng chưa giải quyết được triệt để và thường làm quá trình huấn luyện kém ổn định. Hệ quả là nếu mô hình mắc một lỗi nhỏ ở đầu câu thì lỗi đó sẽ lan truyền và làm sai lệch ngữ cảnh cho các dự đoán tiếp theo từ đó gây ra hiện tượng lỗi bị tích lũy xuyên suốt. Ngoài ra Ranzato và cộng sự [9] đã chỉ ra rằng sự phụ thuộc quá mức vào lịch sử cục bộ khiến Transformer dễ rơi vào các vòng lặp hoặc sinh ra bản dịch vô nghĩa khi gặp các câu phức dài.

- **Cơ chế sinh tuần tự cứng nhắc** các mô hình Transformer tiêu biểu bị giới hạn bởi cơ chế sinh tuần tự từ trái sang phải, thiếu đi khả năng tinh chỉnh lặp lại. Con người khi dịch văn bản thường phác thảo văn bản sẵn rồi tinh chỉnh, nhưng đối với transformer thì khi dịch từ trước đó thì không còn cách nào quay lại để sửa chữa nữa [3]. Cách tiếp cận này ngăn cản mô hình tận dụng thông tin ngữ cảnh toàn bộ câu để sửa đổi các quyết định trong quá khứ. Mặc dù các mô hình Non-Autoregressive Transformer hay còn gọi là NAT [5] đã được đề xuất để tăng tốc độ, nhưng chúng thường đánh đổi bằng sự sụt giảm đáng kể về chất lượng dịch do không nắm bắt được sự phụ thuộc phức tạp giữa các từ đích. Việc thiếu cơ chế sửa lỗi linh hoạt khiến các giải pháp hiện tại khó đạt được chất lượng tương đương quy trình chỉnh sửa liên tục từ bản nháp của con người trong các tác vụ phức tạp.
- **Thiếu hụt các chuẩn đánh giá thực tế và toàn diện:** Đa số các nghiên cứu đề xuất kiến trúc mới (như Diffusion cho văn bản) thường chỉ so sánh với các mô hình Transformer cơ sở được huấn luyện từ đầu. Tuy nhiên, việc so sánh với các mô hình tiền huấn luyện như mBART hay T5 [8] vẫn vô cùng quan trọng để chỉ ra hiệu quả của từng phương pháp. Việc bỏ qua so sánh với các mô hình Pre-trained được tinh chỉnh sẽ tạo ra một đánh giá thiếu khách quan về tính ứng dụng thực tế của giải pháp mới. Cần phải trả lời câu hỏi: Liệu chi phí tính toán lớn của Mô hình Khuếch tán có thực sự đem lại hiệu quả vượt trội so với việc tinh chỉnh các mô hình đã có sẵn nền tảng tri thức ngôn ngữ hay không?

1.1.3 Nhu cầu cấp thiết

Để giải quyết những vấn đề trên, yêu cầu đặt ra là phải tìm được một model có khả năng sinh câu và chỉnh sửa song song và lặp lại. Và diffusion model vốn đã rất thành công trong lĩnh vực sinh ảnh, được chúng tôi xử lý cho việc sinh văn bản. Tư tưởng chính của phương pháp đề xuất là coi quá trình dịch thuật không phải là dự đoán từ kế tiếp, mà là một quá trình khử nhiễu liên tục từ một phân phối ngẫu nhiên về văn bản đích mong muốn. Ngoài ra, nghiên cứu cũng thử với các mô hình tiền huấn luyện, thử finetune và so sánh nó với nhữn kiến trúc đã xây dựng.

1.2 Mục tiêu dự án

Mục tiêu tổng quát của dự án là xây dựng, huấn luyện và đánh giá hiệu năng của phương pháp Dịch máy dựa trên mô hình Khuếch tán và mô hình transformer ngoài ra còn so sánh với các mô hình pretrained có và không finetune để tìm ra ưu nhược điểm của từng mô hình. Các mục tiêu cụ thể bao gồm:

1. Nghiên cứu lý thuyết: Tìm hiểu sâu về cơ chế hoạt động của Diffusion Model bao gồm quá trình thêm nhiễu và khử nhiễu và phương pháp áp dụng lên dữ liệu rời rạc.
2. Code: Cài đặt và huấn luyện mô hình Transformer [11] Re transformer, Diffusion model cho dịch máy. Trên cơ sở đó so sánh với các mô hình pretrained dành riêng cho dịch máy Anh Việt và finetune các mô hình cùng tham số để so sánh hiệu quả.

3. Thực nghiệm và Đánh giá: Huấn luyện cả ba mô hình trên cùng một tập dữ liệu chuẩn. Chạy các mô hình pretrained và finetune để đánh giá và so sánh, rút ra ưu nhược điểm của từng phương pháp. Sau đó so sánh với nhau thông qua các chỉ số định lượng như BLEU và PPL. Ngoài ra, dịch thử để quan sát định tính thay vì chỉ dựa vào các con số.

1.3 Phạm vi dự án

Để đảm bảo tính khả thi và tập trung vào mục tiêu cốt lõi, dự án sử dụng bộ dữ liệu chuẩn IWSLT15 English-Vietnamese. Một số thông tin về tập dữ liệu: Kích thước trung bình vào khoảng 133.000 cặp câu, phù hợp với tài nguyên tính toán cá nhân nhưng vẫn đảm bảo độ tin cậy khoa học. Ngoài ra, dự án chỉ tập trung vào bài toán dịch văn bản đơn ngữ, không bao gồm dịch hội thoại hay đa phương thức thích hợp cho một nghiên cứu mang tính khảo sát. Nghĩa là so sánh hai phương pháp để đưa ra kết luận về ưu nhược điểm, từ đó các nghiên cứu sau sẽ phát triển thêm nếu có cơ hội.

1.3.1 Giới hạn

- Không tập trung tối ưu hóa tốc độ suy diễn thời gian thực do đặc thù Diffusion chậm hơn Autoregressive. Trọng tâm dự án là phát hiện ra ưu điểm của các phương pháp.
- Không xây dựng ứng dụng Web hay App hoàn chỉnh cho người dùng cuối sản phẩm đầu ra là mã nguồn, script chạy thực nghiệm và báo cáo kết quả.
- Không sử dụng các Pre-trained Model quá lớn để fine-tune, mà thực hiện huấn luyện từ đầu để đảm bảo tính công bằng trong so sánh kiến trúc.
- Không phải đề xuất mô hình có thể tốt hơn transformer nhưng là một khảo sát để tìm ra một mô hình có thể tiên năng giải quyết những vấn đề hiện có của transformer.

Chương 2

Nghiên cứu liên quan

Hiện nay các nghiên cứu tập trung vào 3 hướng chính: [1] Dịch máy Nơ-ron Tự hồi quy có ưu thế về độ chính xác về mặt định lượng; [2] Dịch máy Nơ-ron Không tự hồi quy tập trung vào tốc độ; và [3] Ứng dụng Mô hình Khuếch tán trong sinh văn bản.

2.1 Dịch máy Nơ-ron Tự hồi quy

Tư tưởng chính của phương pháp này là sinh tuần tự các token phía sau dựa vào câu đầu vào và các token đã sinh ra trước đó.

Khởi nguồn từ kiến trúc RNN và LSTM. Sutskever và cộng sự [10] đã đề xuất sử dụng hai mạng LSTM để mã hóa câu nguồn thành vector embedding và giải mã thành câu đích. Tuy nhiên, hạn chế của nó là gặp phải hiện tượng bottleneck do nén thông tin về ngữ nghĩa vào một vector có độ dài cố định.

Để giải quyết vấn đề này, Bahdanau và cộng sự [1] đã giới thiệu attention, cho phép tập trung vào các token khác trong câu khi dịch. Dù đã cải thiện được chất lượng dịch nhưng quá trình huấn luyện vẫn rất chậm do không thể song song hóa.

Bước ngoặt thực sự đến khi Vaswani và cộng sự [11] đề xuất kiến trúc Transformer chỉ sử dụng cơ chế Self-Attention. Kiến trúc này đã giải quyết vấn đề huấn luyện chậm và bottleneck bằng cơ chế tính song song hóa và nắm bắt các phụ thuộc xa. Dù vậy nó vẫn tồn tại các nhược điểm như suy luận chậm do cơ chế tự hồi quy và vấn đề Exposure Bias khiến lỗi bị tích lũy [2].

2.2 Dịch máy Nơ-ron Không tự hồi quy

Hướng nghiên cứu này sinh ra để khắc phục nhược điểm tốc độ suy luận của phương pháp tự hồi quy, mang tư tưởng sinh toàn bộ câu một lúc.

Để đặt nền móng cho hướng nghiên cứu này, Gu và cộng sự [5] đã đề xuất mô hình NAT. Ý tưởng là dự đoán độ dài của câu và sinh ra tất cả các từ một cách độc lập. Rất dễ để nhận ra nhược điểm chí mạng của phương pháp này multimodality problem vì các từ được sinh độc lập nên rất dễ bị nhầm các từ đồng nghĩa dẫn đến bị lặp từ và thiếu từ.

Để giảm thiểu sự sụt giảm chất lượng này, Ghazvininejad và cộng sự [3] đã đề xuất phương pháp CMLM với thuật toán Mask-Predict. Khác với cách trên, nghiên cứu này dịch câu lặp đi lặp lại: che những từ có độ tin cậy thấp và dự đoán lại chúng dựa trên ngữ cảnh toàn cục. Nghiên cứu đã cải thiện được độ chính xác so với NAT gốc nhưng vẫn thua kém so với Transformer.

2.3 Mô hình Khuếch tán cho Sinh văn bản

Đây là hướng nghiên cứu mới nhất trong thời gian gần đây, lấy tư tưởng chính từ quá trình xử lý ảnh. Với phương pháp này, quá trình sinh văn bản được coi như việc khử nhiễu liên tục từ một câu văn đã bị nhiễu hoàn toàn.

Nền tảng của hướng này được đặt bởi Ho và cộng sự [6] với mô hình DDPM cho ảnh. Điểm khó khăn là dữ liệu ảnh là dữ liệu liên tục trong khi đó văn bản lại được coi là các token rời rạc, do vậy không thể áp dụng trực tiếp tư tưởng này cho văn bản.

Để giải quyết vấn đề này, Li và cộng sự [7] đã đề xuất Diffusion-LM, tạo ra một lớp embedding để ánh xạ các từ rời rạc vào không gian vector liên tục Gaussian, từ đó thực hiện việc tạo nhiễu và khử nhiễu trên chính các vector liên tục này. Ngoài ra, các nghiên cứu gần đây như DiffuSeq [4] đã mở rộng ý tưởng này sang các tác vụ Sequence-to-Sequence. Phương pháp này đã tạo ra cách dịch đa dạng và cơ chế sửa lỗi linh hoạt hơn so với transformer gốc. Đây cũng chính là cơ sở lý thuyết cho phương pháp được đề xuất trong báo cáo này.

Chương 3

Cơ sở lý thuyết

3.1 Bài toán Dịch máy Nơ-ron

Dịch máy Nơ-ron (Neural Machine Translation - NMT) là phương pháp được sử dụng rộng rãi, trong đó một mạng nơ-ron nhân tạo được huấn luyện để dịch từ chuỗi ngôn ngữ nguồn sang chuỗi ngôn ngữ đích. Ví dụ dịch từ Tiếng Anh sang Tiếng Việt thì ngôn ngữ nguồn là Tiếng Anh còn ngôn ngữ đích là Tiếng Việt.

3.1.1 Khung kiến trúc Encoder-Decoder

Hầu hết các hệ thống dịch máy hiện đại được thiết kế gồm 2 khối: Mã hóa - Giải mã. Đầu tiên về bộ mã hóa có chức năng Chuyển đổi chuỗi đầu vào X thành một tập hợp các vector biểu diễn ngữ cảnh trong không gian liên tục $\mathbf{H} = \{\mathbf{h}_1, \dots, \mathbf{h}_N\}$. Còn về bộ giải mã sử dụng thông tin từ các vector $\mathbf{H}$ và trạng thái ẩn hiện tại để dự đoán phân phối xác suất của từ tiếp theo y_t trong bộ từ vựng $\mathcal{V}_t$.

3.1.2 Huấn luyện và Tối ưu hóa

Quá trình huấn luyện mô hình nhằm mục đích tìm ra bộ tham số tối ưu θ^* sao cho xác suất được tính toán cho các câu đích đúng trong tập huấn luyện D là cao nhất. Điều này tương ứng với việc tối đa hóa hàm log likelihood:

$$\mathcal{L}(\theta) = \sum_{(X,Y) \in \mathcal{D}} \log P(Y|X; \theta) = \sum_{(X,Y) \in \mathcal{D}} \sum_{t=1}^M \log P(y_t|y_{<t}, X; \theta) \quad (3.1)$$

Trong học sâu nói chung, chúng ta thường giải bài toán tìm min nên thay vì tối đa hóa hàm trên chúng ta tối thiểu hóa hàm mất mát Cross-Entropy tức là chuyển dấu của phương trình trên để đưa bài toán từ maximum thành minimum:

$$J(\theta) = -\frac{1}{|\mathcal{D}|} \sum_{(X,Y) \in \mathcal{D}} \log P(Y|X; \theta) \quad (3.2)$$


3.2 Kiến trúc Transformer

Mô hình Transformer [11] ra đời và đánh dấu bước chuyển đổi to lớn trong xử lý ngôn ngữ tự nhiên khi loại bỏ hoàn toàn các thành phần hồi quy của RNN và tích chập của CNN và thay vào đó dựa hoàn toàn vào cơ chế Attention để mô tả sự phụ thuộc giữa các đầu vào và đầu ra. Vì cơ chế đó, nên quá trình huấn luyện trở nên nhanh hơn do quá trình song song hóa.

Kiến trúc tổng quát của Transformer được mô tả cụ thể ở trong hình 3.1.

- **Encoder:** Một block bao gồm 6 lớp giống nhau. Mỗi lớp có hai tiểu lớp chính đó là cơ chế Multi Head Self Attention và mạng nơ ron thẳng theo vị trí.
- **Decoder:** Cũng bao gồm 6 lớp giống nhau nhưng được bổ sung thêm cơ chế cross attetion cho mỗi lớp.

Xung quanh mỗi lớp đều sử dụng Residual Connection theo sau là Layer Normalization.



Hình 3.1: Kiến trúc tổng quát của mô hình Transformer [11].

3.2.1 Cơ chế Scaled Dot-Product Attention

Đầu vào bao gồm các ma trận truy vấn (Q), khóa (K) có chiều d_k , và giá trị (V) có chiều d_v . Transformer không sử dụng các phép toán cộng mà sử dụng phép toán tích vô hướng để tính độ tương đồng giữa Q và K :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (3.3)$$

Trong đó, $\frac{1}{\sqrt{d_k}}$ được thêm vào phép tính nhằm ổn định giá trị của tích vô hướng.


3.2.2 Cơ chế Multi-Head Attention

Transformer chiếu các ma trận lên h không gian tuyến tính (còn gọi là các head). Điều này cho phép mô hình có thể hiểu được các ngữ nghĩa khác nhau của cùng một từ. Ví dụ như từ apple mang nghĩa là quả táo, nhưng cũng có thể là chỉ đến hãng điện thoại apple....


$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (3.4)$$

trong đó mỗi $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$.

Scaled Dot-Product Attention



Multi-Head Attention



Hình 3.2: (Trái) Scaled Dot-Product Attention. (Phải) Multi-Head Attention bao gồm nhiều lớp attention chạy song song.

3.2.3 Mã hóa vị trí

Khác với các cơ chế khác như RNN hay CNN. Mô hình transformer thực hiện song song hóa trên tất cả các token, vì vậy thông tin về vị trí phải được xuất hiện trong vector embedding. Vì thế, các vector vị trí sẽ được cộng trực tiếp vào vector embedding để lưu giữ thông tin về vị trí trong câu. Các vector này sử dụng hàm sin và cos với tần số khác nhau:

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}}) \quad (3.5)$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}}) \quad (3.6)$$

3.2.4 Cơ chế giải mã Tự hồi quy

Quá trình sinh văn bản trong kiến trúc transformer diễn ra tại thành phần decoder. Diễn ra một cách tuần tự và các từ sinh ra tiếp theo sẽ phụ thuộc chặt chẽ vào từ đã sinh ra trước đó. Để mô hình không nhìn trước các token tương lai, trước khi đưa vào Softmax, sau bước nhân ma trận truy vấn và ma trận khóa sẽ cộng thêm các giá trị âm vô cùng.

Xác suất của câu đích Y được phân rã thành tích chuỗi:

$$P(Y|X) = \prod_{t=1}^M P(y_t|y_{<t}, X) \quad (3.7)$$

Tại mỗi bước thời gian t , mô hình dự đoán từ y_t dựa vào các từ đã được sinh ra trước đó $y_{<t}$. nhược điểm của cơ chế này đã được nêu cụ thể ở phần 1.1.2, nơi sai số ở các bước đầu có thể lan truyền và tích lũy về sau.

3.3 Mô hình Diffusion

Ý tưởng của Diffusion là việc huấn luyện một mô hình có khả năng từng bước giải nhiễu, từ một câu chưa hoàn chỉnh giải mã từng bước để có được câu hoàn chỉnh cuối cùng. Huấn luyện Diffusion có 2 pha: pha thứ nhất ta thực hiện làm nhiễu câu gốc theo một tỉ lệ ngẫu nhiên, pha thứ hai ta huấn luyện mô hình có thể giải nhiễu câu gốc khi biết trước tỉ lệ nhiễu đó. Sau khi đã học được cách giải nhiễu, ở phần suy luận, mô hình sẽ thực hiện giải nhiễu từng bước theo một lịch trình được lập sẵn. Cụ thể huấn luyện như nào, suy luận ra sao sẽ được trình bày cụ thể hơn trong các mục con dưới đây.

3.3.1 Một số định nghĩa

Phần này trình bày một số định nghĩa và ký hiệu, tuy không dài nhưng quan trọng để hiểu các nội dung ở phần sau.

Kí tự **MASK** là token đặc biệt được sử dụng để chỉ rằng đang có một token nào đó bị che đi cần được mở ra. Loại token này không mới, nó đã xuất hiện trên các mô hình ngôn ngữ masked chẳng hạn như BERT để học cách đoán ra token ở vị trí được mask. Trong mô hình Diffusion, token này cũng có vai trò tương tự được hiểu là “làm nhiễu”, thêm vào để thách thức mô hình giải mã được các phần bị nhiễu. Để thuận tiện, chúng tôi kí hiệu token này là $\mathcal{M}$.

Thời gian, kí hiệu t , là một thành tố quan trọng, thể hiện giai đoạn nhiễu hay mức độ nhiễu trong huấn luyện và suy luận của mô hình. Để thuận tiện, ta chuẩn hóa $t \in [0, 1]$, trong đó $t = 0$ nghĩa là câu không bị nhiễu hay không còn nhiễu, $t = 1$ nghĩa là câu bị nhiễu hoàn toàn.

3.3.2 Làm nhiều

Làm nhiều là pha đầu tiên trong hai pha huấn luyện. Trong bước này, ta lấy mẫu x_t là nhiều của x_0 ở bước thời gian t theo phân phối $q(x_t|x_0, t)$.

$$x_t \sim q(x_t|x_0, t) \quad (3.8)$$

Mục đích làm nhiều như vậy để thu được một câu có một số lượng token nhất định (phụ thuộc vào t) bị mask. Ta nhận định rằng, việc làm nhiều một câu thực chất là mỗi token được làm nhiều một cách độc lập có điều kiện, trong đó điều kiện chỉ là duy nhất bản thân token đó. Vì vậy, ta có thể phân rã:

$$q(x_t|x_0, t) = \prod_{i=1}^L q(x_t^i|x_0^i, t) \quad (3.9)$$

Trong đó, x_t^i là token thứ i của x_t , phân phối $q(x_t^i|x_0^i, t)$ là phân phối làm nhiều của token vị trí i , được định nghĩa xác suất như sau:

$$q(x_t^i|x_0^i, t) = \begin{cases} t & x_t^i = \mathcal{M} \\ 1 - t & x_t^i = x_0^i \end{cases} \quad (3.10)$$

Tham số t thể hiện bước thời gian của quá trình làm nhiều. Có nhiều cách để chọn t , nhưng phải chọn làm sao để mô hình học được nhiều giá trị khác nhau của t nhất. Cách đơn giản mà hiệu quả nhất là lấy ngẫu nhiên giá trị t :

$$t \sim \text{U}(0, 1) \quad (3.11)$$

3.3.3 Học giải nhiều

Sau khi đã làm nhiều với thời gian t , ở pha này, ta cần tìm cách giải nhiều từ x_t về x_0 . Tương tự với pha làm nhiều, trong pha giải nhiều ta cũng có $p(x_0|x_t)$ là phân phối giải nhiều. Ta nhận định rằng, việc giải nhiều một câu thực chất là mỗi token được giải nhiều độc lập có điều kiện, trong đó điều kiện là gồm toàn bộ các token trong câu. Vì thế ta có thể phân rã thành:

$$p(x_0|x_t) = \prod_{i: x_t^i = \mathcal{M}} p(x_0^i|x_t) \quad (3.12)$$

Trong đó, i chỉ chạy trong tập hợp vị trí các token bị mask. Như vậy, bài toán của chúng ta có thể quy về bài toán dự đoán token bị mask khi biết ngữ cảnh của câu. Đến đây, ta bố trí một mạng $f_\theta(x_t)_i$ nhận giá trị đầu vào là toàn bộ ngữ cảnh x_t , đầu ra là một vector $|V|$ chiều là vector giá trị logit mỗi token trong vocabulary. Khi này phân phối $p(x_0^i|x_t)$ được mô hình tham số hóa thành:

$$p_\theta(x_0^i|x_t) = \text{softmax}(f_\theta(x_t)_i) \quad (3.13)$$

Mạng $f_\theta(x_t)$ có thể là bất kỳ mạng nào thỏa mãn đầu vào đầu ra, nhưng nên là một mô hình mask phi nhân quả và sử dụng cơ chế attention. Việc tiếp theo đơn giản huấn luyện mô hình học ra cách dự đoán tốt nhất, dựa theo hàm loss sau:

$$\mathcal{L}(\theta) = -\frac{1}{t} \cdot \sum_{i : x_t^i = \mathcal{M}} \log p_\theta(x_0^i | x_t) \quad (3.14)$$

Hàm loss trên tương tự như Cross Entropy vì mô hình học cách dự đoán token để giải nhiễu. Đến đây, bước thời gian t mới bắt đầu được dùng, cụ thể ta lấy cụm log-likelihood chia cho t để chuẩn hóa. Sở dĩ ta làm như vậy, trước hết là để đảm bảo công bằng cho mỗi giá trị t , khi mà t lớn (nhiều cao) thì mô hình dễ đoán sai hơn so với t nhỏ (nhiều thấp), đồng thời giúp mô hình nhận thức được sự khác biệt trong hành động cần làm khi t khác nhau.

3.3.4 Giải nhiễu có điều kiện

Ta biết rằng để từ một prompt p_0 đầu vào và sinh được một phản hồi r_0 đầu ra, mô hình Diffusion không được trực tiếp huấn luyện để học ra phép ánh xạ đó. Trên lý thuyết, Diffusion được huấn luyện để từ một câu chưa hoàn chỉnh giải mã thành một câu hoàn chỉnh. Vì thế, nếu muốn sinh một câu đầu ra r_0 từ một đầu vào p_0 , ta sẽ coi p_0 như là một dữ kiện của quá trình giải nhiễu và gọi nó là giải nhiễu có điều kiện.

Cụ thể, phân phối giải nhiễu có dạng $p_\theta(r_0 | p_0, r_t)$. Trong đó, p_0 được thêm vào mà không bị nhiễu, cung cấp thêm thông tin cho mô hình để giải nhiễu.

3.3.5 Suy luận

Mỗi lần suy luận, ta cần chọn N là số bước để giải mã từ một câu hoàn toàn nhiễu đến một câu hoàn chỉnh, đồng thời lập lịch t giảm dần $[t_1, \dots, t_N]$, trong đó $t_1 = 1$ và $t_N = 0$. Như vậy, trạng thái ban đầu của câu nhiễu là:

$$x_{t_1} = (p_0, \mathcal{M}, \dots, \mathcal{M})$$

Ta tiến hành duyệt N bước để tiến hành suy luận. Tại bước thứ n , ta thực hiện dự đoán vị trí tại tất cả các token đang bị mask.

$$\hat{x}_0^i = \operatorname{argmax} p_\theta(x_0^i | x_{t_n}) \quad (3.15)$$

Ở bất kỳ bước nào, tất cả các token bị mask đều được dự đoán. Tuy nhiên, sẽ chỉ có một số được cố định hoàn toàn, một số bị mask trở lại, và còn lại thì không bị mask cũng không cố định.

Trong mỗi bước, sẽ có một số lượng các token được cố định, nghĩa là chúng sẽ không bao giờ bị mask nữa. Điều này nhằm đảm bảo tính đúng đắn cho thuật toán rằng đến bước cuối cùng sẽ không còn token nào bị mask, đồng thời đảm bảo câu được từng bước sinh ra, bước sau tận dụng được thông tin đã giải mã từ bước trước. Cụ thể, tại bước t_n , ta phải đảm bảo rằng có ít nhất tỉ lệ $1 - t_n$ token đã được cố định. Nếu chưa đủ, ta thực hiện chọn một số token trong số các token chưa được cố định dựa trên xác suất, rồi đánh dấu chúng là các token cố định.

Trong số các token còn lại chưa được cố định, ta thực hiện mask ngẫu nhiên một trong số chúng:

$$x_{t_{n+1}}^i = \begin{cases} \mathcal{M} & \text{với xác suất } \frac{t_{k+1}}{t_k} \\ \hat{x}_0^i & \text{ngược lại} \end{cases} \quad (3.16)$$

Quá trình được lặp lại, cho đến khi đủ N bước thì sẽ thu được $x_0 = (p_0, r_0)$ không còn nhiều. Ta thực hiện tách r_0 để lấy được kết quả phản hồi.

Chương 4

Phương pháp thiết kế

4.1 Mô hình xương sống

Mô hình $p_\theta(x_0|x_t)$ đề cập ở phương trình 3.13 có thể được mô hình bằng một mạng nơ-ron đơn giản hoặc một mạng phức tạp như một mô hình Transformer. Trong nghiên cứu này, chúng tôi sử dụng một mô hình ngôn ngữ mask thuộc họ RoBERTa, cụ thể là PhoBERT-base làm mạng xương sống. Mô hình có khoảng 135 triệu tham số, được huấn luyện trên lượng lớn dữ liệu tiếng Việt nên có khả năng hiểu tốt các câu tiếng Việt. Tận dụng mô hình này sẽ giúp chúng tôi tiết kiệm tài nguyên để huấn luyện mô hình Diffusion.

4.2 Tiền huấn luyện

Mặc dù mô hình PhoBERT-base đã được tiền huấn luyện với một lượng lớn dữ liệu tiếng Việt, nhưng nó chưa được tiền huấn luyện với đầu vào là một cặp song ngữ, vậy nên nó chưa thể hiểu rõ mối liên hệ giữa hai ngôn ngữ này. Chúng tôi quyết định tiền huấn luyện lại mô hình này một lần nữa, là để giúp mô hình hiểu được ... bla bla bla

Thuật toán tiền huấn luyện cụ thể như sau:

Algorithm 1 Tiền huấn luyện

Require: mô hình p_θ , tập dữ liệu $\mathcal{D}$

- 1: **repeat**
 - 2: $x_0 \sim \mathcal{D}$
 - 3: $t \sim \text{U}(0, 1]$
 - 4: $x_t \sim q(x_t|x_0)$ # $q_{t|0}$ is defined in Eq. (??)
 - 5: Tính và tối ưu $\mathcal{L} = -\frac{1}{t \cdot L} \sum_{i=1}^L \mathbf{1}[x_t^i = \mathcal{M}] \log p_\theta(x_0^i|x_t)$ # L là độ dài x_0
 - 6: **until** Hội tụ
 - 7: **Return** p_θ
-

4.3 Huấn luyện

Thuật toán huấn luyện như sau

Algorithm 2 Huấn luyện mô hình Diffusion

Require: mô hình p_θ , tập dữ liệu $\mathcal{D}$

- 1: **repeat**
 - 2: $p_0, r_0 \sim \mathcal{D}$
 - 3: $t \sim \text{U}(0, 1)$
 - 4: $r_t \sim q(r_t | r_0)$ # $q_{t|0}$ is defined in Eq. (??)
 - 5: Tính và tối ưu $\mathcal{L} = -\frac{1}{t \cdot L} \sum_{i=1}^L \mathbf{1}[r_t^i = \mathcal{M}] \log p_\theta(r_0^i | p_0, r_t)$
 - 6: **until** Hội tụ
 - 7: **Return** p_θ
-

4.4 Suy luận

Thuật toán suy luận như sau

Algorithm 3 Suy luận

Require: mô hình p_θ , đầu vào p_0 , độ dài phản hồi L , số bước giải nhiễu N

- 1: Gán r_1 gồm L token $\mathcal{M}$.
 - 2: **for** $t \leftarrow 1$ **down to** $\frac{1}{N}$ **step** $\frac{1}{N}$ **do**
 - 3: $\tau = t - \frac{1}{N}$
 - 4: $r_0 = \arg \max_{r_0} p_\theta(r_0 | p_0, r_t)$
 - 5: **for** $i \leftarrow 1$ **to** L **do**
 - 6: **if** $r_t^i \neq \mathcal{M}$ **then**
 - 7: $r_0^i = r_t^i$
 - 8: **else**
 - 9: $r_0^i = \mathcal{M}$ với xác suất $\frac{\tau}{t}$
 - 10: **end if**
 - 11: **end for**
 - 12: **end for**
 - 13: **Return** r_0
-

Chương 5

Kết quả

Để chứng minh hiệu quả của phương pháp và rút ra ưu nhược điểm của từng phương pháp, chúng tôi đã tiến hành thực nghiệm trên tập IWSLT 15 với các model nhóm xây dựng từ đầu như Transformer base, Re transformer và Diffusion model. Ngoài ra, còn so sánh với mô hình pretrained sẽ nói cụ thể ở phần sau, cuối cùng là trả lời các câu hỏi nghiên cứu (RQ):

- **RQ1** Diffusion đã cải thiện được gì trong quá trình dịch so với Transformer, và nó tồn tại những nhược điểm nào? Đây là RQ quan trọng nhất của bài.
- **RQ2** Khi nào nên finetune và khi nào nên train from scratch?
- **RQ3** Các mô hình đã pretrained chuyên cho các tác vụ dịch Anh-Việt có nên được dùng thay thế trong trường hợp nào?

5.1 Tổng hợp kết quả định lượng

Bảng 5.1 trình bày tổng quan kết quả thực nghiệm của các mô hình được nhắc đến trong nghiên cứu này, cụ thể là bleu score và PPL:

Nhận xét chung: Qua bảng số liệu 5.1, ta thấy các mô hình pretrained với tiêu biểu là mBART, đạt kết quả BLEU cao nhất nhờ được huấn luyện trên lượng dữ liệu đa ngôn ngữ khổng lồ.

Trong nhóm các mô hình huấn luyện từ đầu, Transformer Base có BLEU cao nhất, trong khi Re-Transformer tuy có BLEU thấp hơn một chút nhưng hiệu năng vẫn là rất ổn nếu so với các mô hình pretrained khác có lượng tham số lớn hơn. Re-Transformer với khoảng 32.5M tham số đạt BLEU 34.51, cao hơn đáng kể so với T5-Tiny 16M tham số đã được finetune với 25.65 BLEU và NlpHUST 60M tham số nhưng là hiệu năng trần với 25.79 BLEU, như vậy nhìn về tổng quan ta thấy ở quy mô trung bình, việc xây dựng một hệ thống train from scratch và bộ tokenizer chuyên biệt tối ưu hơn rất nhiều. Điển hình với transformer base có thể đánh bại các mô hình khác với rất nhiều tham số và đã được tinh chỉnh trên bộ dữ liệu khổng lồ chỉ mang lại độ tự tin khi dự đoán từ cao nhưng hiệu quả dịch vẫn không bằng.

Về các chỉ số đánh giá, ở các mô hình pretrained như T5-Tiny, NlpHUST ta thấy chỉ số PPL rất thấp, nằm trong khoảng 2.17–2.46 do việc tiền huấn luyện giúp mô hình dự

Bảng 5.1: Kết quả thực nghiệm so sánh BLEU và PPL giữa các mô hình.

Nhóm	Mô hình	Tham số	BLEU	PPL
Transformer	Transformer Base	~25.5M	38.91	9.97
	Re-Transformer	~32.5M	34.51	14.82
Diffusion	Diffusion (T=50)	~ 135M	20.4 ± 3.9	1.75
	Diffusion (T=100)	~ 135M	23.6 ± 4.5	1.64
	Diffusion (T=200)	~ 135M	21.4 ± 4.1	1.74
Fine-tuning	T5-Tiny (Fine-tuned)	~16M	25.65	2.17
Mô hình có sẵn	Helsinki-NLP/ opus-mt-en-vi	~77M	29.85	7.39
	NlpHUST/ t5-en-vi-small	~60M	25.79	2.46
	Facebook/mBART-large-50-many-to-many-mmt	600M+	34.56	5.66

đoán với độ tự tin cao. Thế nhưng chúng tôi cho rằng trong bài toán này PPL không phản ánh được chất lượng dịch khi các mô hình pretrained khác với tham số to hơn mang lại bleu score cao hơn.

Kết luận: Đối với bài toán dịch máy, BLEU là thước đo được ưu tiên vì phản ánh trực tiếp mức độ tương đồng với bản dịch của con người, trong khi PPL chủ yếu mang ý nghĩa tham khảo về mức độ tự tin của mô hình ngôn ngữ. Cho nên trong bài báo chúng tôi cũng ưu tiên bleu score hơn.

5.2 Phân tích chi tiết và Thảo luận

5.2.1 Các mô hình tiền huấn luyện (Pre-trained Models)

Trong nghiên cứu này, chúng tôi sử dụng các mô hình pretrained như một tham chiếu để chứng minh chất lượng của các mô hình huấn luyện từ đầu. mBART-large-50 của Facebook là mô hình khổng lồ với 600M tham số và được huấn luyện trên 50 loại ngôn ngữ khác nhau. Helsinki-NLP là một mô hình với 77M tham số, được huấn luyện trên tập dữ liệu OPUS đa dạng miền, trong nghiên cứu này chúng tôi sử dụng mô hình này chuyên dụng cho dịch máy Anh Việt, đại diện cho nhóm được tiền huấn luyện chuyên biệt. Đối với họ T5, nghiên cứu sử dụng T5-Tiny và NlpHUST t5-en-vi-small. Với NlpHUST t5-en-vi-small khoảng 60M tham số đã được tiền huấn luyện chuyên biệt cho bài toán dịch Anh Việt với vai trò cũng giống như Helsinki-NLP là một thước đo với các mô hình với tham số lớn và được tiền huấn luyện trên dữ liệu Anh Việt. Còn T5 tiny là một mô hình pretrained lightweight và được sử dụng để finetune và so sánh.

5.2.2 Trả lời câu hỏi nghiên cứu

Trả lời RQ1: Phân tích sự khác biệt giữa cơ chế sinh tự hồi quy (Autoregressive) của Transformer và cơ chế sinh song song/lặp lại của Diffusion.

Bảng 5.2: Sự thay đổi đầu ra giữa các lần suy luận của mỗi mô hình

Mô hình	Mẫu suy luận
Câu cần dịch	I am a student at UET and currently live in Hanoi.
Transformer	tôi là sinh viên ở <unk> và hiện tại đang sống ở <unk> tôi là sinh viên ở <unk> và hiện tại đang sống ở <unk> tôi là sinh viên ở <unk> và hiện tại đang sống ở <unk>
Diffusion	Tôi là sinh viên ở UET và đang sống ở đây, đó là nơi tôi ở. Tôi từng là một học sinh ở UET và hiện nay ở Hanoi, được nhiều năm. Tôi là sinh viên ở UET và hiện đang sinh sống ở Hà Nội.

Chất lượng dịch: Mô hình Transformer vẫn giữ vững phong độ là một state-of-the-art, đạt điểm BLEU cao hơn, cho thấy khả năng nắm bắt ngữ nghĩa và ngữ pháp tốt trên tập dữ liệu nhỏ. Mô hình Diffusion đạt BLEU kém hơn nhưng lại cho thấy khả năng sinh ra các câu đa dạng về từ vựng, dẫn đến biên độ dao động BLEU mỗi lần đánh giá.

Độ đa dạng: Quá trình lựa chọn của Transformer là đơn định (deterministic), luôn cho ra một kết quả tốt nhất. Diffusion với Random Remasking (RR) lại là một quá trình ngẫu nhiên có kiểm soát, cho phép sinh ra các câu khác nhau nhưng vẫn giữ đúng ý nghĩa. Ngược lại, chiến lược Low-confidence Remasking (LR) gặp tình trạng đơn định tương tự Transformer.

Quá trình hội tụ: Hai mô hình sử dụng hàm loss cho các mục tiêu khác nhau nên so sánh giá trị loss trực tiếp không mang nhiều ý nghĩa. Tuy nhiên, Diffusion cho thấy tiềm năng sinh câu với độ phức tạp thời gian hằng số và khả năng tự sửa lỗi, mặc dù chi phí tính toán và độ nhất quán vẫn là những thách thức cần giải quyết.

Trả lời RQ2: Hiệu quả giữa Fine-tuning mô hình nhỏ và Huấn luyện từ đầu

Khi so sánh T5-Tiny (nhóm Fine-tuning) với các kiến trúc Transformer và Re-Transformer (huấn luyện từ đầu), kết quả thực nghiệm trên tập IWSLT15 đã chỉ ra một thực tế quan trọng. Mặc dù T5-Tiny sở hữu lợi thế từ quá trình tiền huấn luyện trên các bộ dữ liệu lớn, giúp mô hình hội tụ rất nhanh và đạt chỉ số PPL thấp hơn hẳn (5.1) so với các mô hình xây dựng từ đầu, nhưng điểm số BLEU thực tế lại cho thấy một góc nhìn khác.

Sự chênh lệch này phản ánh rõ ràng về mức độ tương thích giữa miền dữ liệu và cấu trúc bộ từ vựng. Trong khi các mô hình Transformer được xây dựng từ đầu chuyên biệt cho cặp dữ liệu Anh-Việt có khả năng xử lý ngữ pháp và ngữ nghĩa tốt hơn, thì mô hình nhỏ như T5-Tiny lại gặp khó khăn khi vận hành bộ Tokenizer đa ngôn ngữ. Chính việc phân mảnh âm tiết quá mức ở các bộ từ vựng tổng quát đã làm suy giảm khả năng hiểu sâu và nắm bắt bản chất đặc thù của tiếng Việt. Rõ ràng, việc tận dụng một mô hình có sẵn thông qua Fine-tuning có thể giúp tiết kiệm đáng kể thời gian triển khai ban

đầu, nhưng để chạm tới chất lượng dịch thuật sắc nét trên một miền dữ liệu cụ thể, việc tự xây dựng và tối ưu lại từ đầu vẫn là hướng đi thực chất và hiệu quả hơn.

Trả lời RQ3: Đánh giá giữa các phương pháp tiếp cận

Dựa trên kết quả thực nghiệm tại bảng 5.1, sự đánh đổi giữa phương pháp Huấn luyện từ đầu và Tinh chỉnh mô hình tiền huấn luyện được thể hiện rõ nét qua hai khía cạnh chủ đạo: hiệu suất dịch thuật và mức độ tiêu tốn tài nguyên.

Đối với phương pháp Huấn luyện từ đầu: Ưu điểm lớn nhất nằm ở khả năng tối ưu hóa kiến trúc theo đúng mục đích. Điều này giúp các mô hình có quy mô tham số vừa phải như Re-Transformer đạt được hiệu suất dịch thực tế vượt trội hơn cả các mô hình tiền huấn luyện trước như NlpHUST. Cách tiếp cận này giúp hệ thống tận dụng tối đa tài nguyên tính toán hiện có, tránh tình trạng lãng phí bộ nhớ cho những tri thức ngôn ngữ dư thừa không thực sự cần thiết cho cặp ngôn ngữ đích. Tuy nhiên, nhược điểm của các mô hình huấn luyện từ đầu là chỉ số PPL thường duy trì ở mức cao hơn so với các mô hình tinh chỉnh thể hiện ở việc không có sự hỗ trợ từ việc tiếp xúc với các kho ngữ liệu khổng lồ ở giai đoạn tiền huấn luyện.

Đối với phương pháp Tinh chỉnh mô hình tiền huấn luyện: Điểm mạnh là tốc độ hội tụ nhanh chóng và khả năng phản ứng nhạy bén với những miền tri thức mới. Khi quy mô mô hình đủ lớn, tiêu biểu như mBART với hơn 600 triệu tham số, sức mạnh của tri thức tiền huấn luyện có thể bù đắp hoàn toàn cho sự thiếu hụt dữ liệu cụ thể để chạm tới chất lượng dịch thuật tối ưu. Tuy nhiên, rào cản lại xuất hiện ở các biến thể nhỏ như T5-Tiny; tại đây, hiện tượng "quên" tri thức cũ và sự không tương thích của bộ từ vựng đã khiến hiệu quả dịch thuật giảm sút đáng kể.

Kết luận và Khuyến nghị: Việc lựa chọn phương pháp nào hoàn toàn tùy thuộc vào điều kiện thực tế của dự án. Phương pháp Huấn luyện từ đầu là giải pháp lý tưởng khi bài toán có yêu cầu cụ thể và đối mặt với các ràng buộc khắt khe về phần cứng. Ngược lại, việc sử dụng các Mô hình tiền huấn luyện nên được ưu tiên hàng đầu trong kịch bản dữ liệu quá khan hiếm không đủ để xây dựng từ đầu hoặc khi mục tiêu tối thượng là đạt được chất lượng dịch thuật cao nhất mà không bị giới hạn bởi tài nguyên tính toán.

Chương 6

Tổng kết

6.1 Kết luận

Thông qua nghiên cứu này chúng ta đã thấy ưu nhược điểm của các mô hình truyền thống trong bài toán dịch máy, cũng như một hướng đi mới có thể phát triển trong tương lai với Diffusion model, mặc dù chưa thể thắng được Transformer về mặt định lượng với chỉ số đo chất lượng dịch thuật là bleu score, nhưng vẫn có những ưu điểm vượt trội khi nhìn cách mà mô hình dịch. Ngoài ra, nghiên cứu cũng đã chỉ ra được ưu nhược điểm của các phương pháp trần hiệu suất, fine tuning và train from scratch để đưa ra kết luận khi nào thì cần dùng phương pháp nào.

6.2 Hướng mở rộng

Do thời gian và tài nguyên hạn chế, nghiên cứu vẫn chưa thể tối ưu cho phương pháp mới diffusion model. Ngoài ra, nghiên cứu vẫn chưa thể scale up số lượng tham số và chỉ ra ảnh hưởng của số lượng tham số đến các mô hình và phương pháp. Các hướng mở rộng có thể áp dụng như sau:

- Tối ưu mặt định lượng của Diffusion model để có thể tương đương với các mô hình transformer.
- Thêm RQ về số lượng tham số các mô hình ảnh hưởng thế nào đến hiệu suất.
- Xây dựng hệ thống hoàn chỉnh về dịch máy.

Tài liệu tham khảo

- [1] Dzmitry Bahdanau. Neural machine translation by jointly learning to align and translate. *arXiv preprint arXiv:1409.0473*, 2014.
- [2] Samy Bengio, Oriol Vinyals, Navdeep Jaitly, and Noam Shazeer. Scheduled sampling for sequence prediction with recurrent neural networks. *Advances in neural information processing systems*, 28, 2015.
- [3] Marjan Ghazvininejad, Omer Levy, Yinhan Liu, and Luke Zettlemoyer. Mask-predict: Parallel decoding of conditional masked language models. *arXiv preprint arXiv:1904.09324*, 2019.
- [4] Shansan Gong, Mukai Li, Jiangtao Feng, Zhiyong Wu, and LingPeng Kong. Diffuseq: Sequence to sequence text generation with diffusion models. *arXiv preprint arXiv:2210.08933*, 2022.
- [5] Jiatao Gu, James Bradbury, Caiming Xiong, Victor OK Li, and Richard Socher. Non-autoregressive neural machine translation. *arXiv preprint arXiv:1711.02281*, 2017.
- [6] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- [7] Xiang Li, John Thickstun, Ishaan Gulrajani, Percy S Liang, and Tatsunori B Hashimoto. Diffusion-lm improves controllable text generation. *Advances in neural information processing systems*, 35:4328–4343, 2022.
- [8] Yinhan Liu, Jiatao Gu, Naman Goyal, Xian Li, Sergey Edunov, Marjan Ghazvininejad, Mike Lewis, and Luke Zettlemoyer. Multilingual denoising pre-training for neural machine translation. *Transactions of the Association for Computational Linguistics*, 8:726–742, 2020.
- [9] Marc’Aurelio Ranzato, Sumit Chopra, Michael Auli, and Wojciech Zaremba. Sequence level training with recurrent neural networks. *arXiv preprint arXiv:1511.06732*, 2015.
- [10] Ilya Sutskever, Oriol Vinyals, and Quoc V Le. Sequence to sequence learning with neural networks. *Advances in neural information processing systems*, 27, 2014.
- [11] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.

Phụ lục A

Thành viên

Thông tin và vai trò của các thành viên trong dự án được đề cập tại bảng A.1. Tuy mỗi thành viên có nhiệm vụ cụ thể, nhưng trong quá trình thực hiện đều có sự tương trợ và phối hợp lẫn nhau giữa các thành viên trong nhóm.

Bảng A.1: Thông tin và nhiệm vụ của các thành viên

STT	Họ và tên	MSSV	Nhiệm vụ chính
1	Lâm Đức Anh	23020326	Đề xuất, tìm hiểu, cài đặt, huấn luyện, đánh giá và hoàn thiện mô hình Diffusion. Viết báo cáo phần Diffusion.
2	Vũ Minh Sơn	23020424	Xây dựng, huấn luyện, đánh giá và hoàn thiện Transformer gốc và Re-Transformer. Làm giao diện demo.
3	Nguyễn Bá Quang	23020412	Viết báo cáo, làm slide, lên kế hoạch thực nghiệm để trả lời các RQ. Tìm và thử nghiệm các mô hình pre trained; tìm và finetune mô hình để so sánh.